

# Protocol: архитектура по этапам

## Навигатор клинических протоколов Минздрава РБ и ориентировочная проверка консультативных заключений (КЗ).

Документ описывает текущую реализацию (MVP), целевую интеграцию с МИС и Минздравом через стандарт FHIR BY / ЦИСЗ, а также предложения по масштабированию на тысячи КЗ в сутки.

Версия документа: 2026-06-02 · Сборка приложения: 2026-06-01-r59 · Не является ТЗ и не заменяет нормативные акты Минздрава.

## 1. Назначение и границы системы

**MVP** Protocol – веб-сервис и API для двух сценариев:

1. **Поиск протоколов** – подбор официальных КП Минздрава РБ по диагнозу, МКБ-10, жалобам и рубрикам каталога.
2. **Проверка КЗ** – ориентировочная сверка консультативного заключения с фрагментами протоколов и формализованными правилами; отчёт для врача и методслужбы.

**Не входит:** установление диагноза, замена очного приёма, МЭЭ, юридически обязательная экспертиза, прямая запись в медицинскую карту (на этапе пилота).

**Два контура intelligence:** (1) **LLM** – языковая модель для синтеза, уточнения запроса и дополнения ответа; (2) **детерминированный слой** `clinical_knowledge/` – парсинг, правила из протоколов, scoring без «магии» модели.

## 2. Этап 0. Корпус протоколов и справочники

### 2.1. Источник данных

Официальный каталог PDF на minzdrav.gov.by (раздел «Стандарты обследования и лечения»).

Синхронизация скриптом `download_minzdrav_protocols.py` в каталог `minzdrav_protocols/` (~478 PDF, 24 рубрики).

### 2.2. Индекс каталога

`index.csv` – метаданные: рубрика, год в имени файла, признак постановления МЗ. Используется для UI-бейджей, статистики презентации и фильтрации.

### 2.3. Справочники

- `protocols.json`, `protocol_meta.json` – реестр путей и метаданные.
- `data/catalog/` – 85 нозологий, 482 автоизвлечённых правила, отчёт покрытия 100% PDF.
- `data/protocol_summaries/` – YAML/JSON карточки протоколов (~465 summaries) для навигации и расширения правил.
- `config/` – требования к КЗ, веса scoring, red flags.

### 3. Этап 1. Подготовка корпуса для RAG

#### 3.1. Два пути сборки (legacy и новый)

| Путь   | Скрипты                                                                                            | Результат                                               |
|--------|----------------------------------------------------------------------------------------------------|---------------------------------------------------------|
| Legacy | <code>extract_corpus.py</code> → <code>build_chunks.py</code> → <code>split_chunks_jsonl.py</code> | <code>corpus_chunks_parts/*.jsonl</code>                |
| Новый  | <code>corpus_pipeline/run_pipeline</code>                                                          | Секции, таблицы, entities → <code>output/chunks/</code> |

#### 3.2. Чанки RAG

~105 000 фрагментов текста с разметкой разделов (диагноз, лечение, обследование). Хранятся в `corpus_chunks_parts/` (JSONL, 7 частей). При старте сервера загружаются в память фоновым потоком.

#### 3.3. Индексы поиска

При загрузке строятся: лексический инвертированный индекс, BM25 ( `retrieval_bm25.py` ), маршрутизация по симптомам ( `symptom_routing.json` ).

## 4. Этап 2. Слой clinical\_knowledge (детерминированный)

Каталог `clinical_knowledge/` (~61 модуль). Публичный API: `clinical_knowledge_status`, `match_protocol_cards`, `run_rule_checker`, `extract_consult_facts_heuristic`.

| Блок       | Модули                                                                                                   | Функция                                                  |
|------------|----------------------------------------------------------------------------------------------------------|----------------------------------------------------------|
| Схемы      | <code>consult_schema.py</code>                                                                           | ConsultationDocument, ComplianceReport, 8 блоков scoring |
| Парсинг КЗ | <code>consult_parser.py</code> , <code>text_extract.py</code> , <code>medication_parser.py</code>        | PDF/TXT/DOCX → структура документа                       |
| Подбор КП  | <code>protocol_match.py</code> , <code>diagnosis_icd.py</code>                                           | Сопоставление с протоколами по МКБ и рубрике             |
| Правила    | <code>rule_checker.py</code> , <code>rules_from_path.py</code>                                           | 482 правила из PDF, покрытие по рубрикам                 |
| Compliance | <code>compliance_engine.py</code> , <code>requirement_checker.py</code> , <code>safety_checker.py</code> | Итоговый отчёт, issues, source_refs                      |
| Summaries  | <code>protocol_summary/</code>                                                                           | Карточки протоколов → rules → RAG chunks                 |
| Отчёты     | <code>consult_report.py</code> , <code>batch_runner.py</code>                                            | HTML/MD для печати, пакетная обработка                   |

Оркестратор: `consult_analysis.analyze_consultation_text()`. В production вызывается из `consult_review_pipeline.py`.

## 5. Этап 3. Runtime: rag\_server.py (FastAPI)

### 5.1. Стек

Python 3.11+, FastAPI, uvicorn. Учётные данные для вызова языковой модели задаются только в конфигурации сервера (переменные окружения или защищённое хранилище секретов) и не передаются в браузер.

### 5.2. Загрузка при старте

Фоновый поток `load_data()` : JSONL-чанки, protocols, meta, summary chunks, BM25. Endpoint `/health` отвечает до полной готовности RAG (важно для health-check при облачном развёртывании и в Kubernetes).

### 5.3. Гибридный retrieve

Функция `retrieve()` : лексика + BM25 + routing boost + фильтр аудитории + опциональный embed-rerank через LLM. Результат – топ фрагментов по протоколам.

### 5.4. Группы API

| Домен              | Endpoints                                                                                                                                                                   |
|--------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Health             | GET <code>/health</code> , <code>/api/version</code> , <code>/api/corpus-stats</code>                                                                                       |
| Поиск              | POST <code>/api/assist</code> , <code>/api/protocol-detail</code> , <code>/api/protocol-practical</code> , <code>/api/kz-matrix</code> , GET <code>/api/protocol-pdf</code> |
| КЗ                 | POST <code>/api/consult-review</code> , <code>/api/consult-review/stream</code> (SSE)                                                                                       |
| Справочники        | <code>/api/specialties</code> , <code>/api/icd-suggest</code> , <code>/api/training-cases</code>                                                                            |
| Аналитика          | <code>/api/presentation-stats</code> , <code>/api/quality-benchmark</code> , <code>/api/pilot-analytics-demo</code>                                                         |
| Clinical knowledge | <code>/api/clinical-knowledge/status</code> , <code>/build-status</code> , <code>/benchmark</code>                                                                          |

## 6. Этап 4. Проверка КЗ (pipeline)

Модуль `consult_review_pipeline.py` – оркестрация с SSE-прогрессом для UI.

PDF/TXT/DOCX

- извлечение текста
- МКБ-10 + якорь рубрики врача
- retrieve (RAG по allowlist протоколов)
- match\_protocol\_cards + run\_rule\_checker
- build\_compliance\_report (детерминированно)
- LLM: синтез критериев и дополнение (если включено)
- structured\_analysis + report\_html + report\_markdown

Флаг `CONSULT_STRUCTURED_ANALYSIS=1` включает полный структурный разбор. Fast mode на production сокращает второй проход RAG и таймауты.


## 7. Этап 5. Frontend (index.html)

Монолитный SPA (~12k строк): inline CSS + vanilla JS, без bundler.

- **Вкладка по умолчанию:** «Проверка КЗ» ( `#consult-review` ).
- **Вторая вкладка:** «Поиск протоколов» ( `#search` ).
- Демо: `?presentation=1` – overlay для показа руководству.
- SSE для потоковой проверки КЗ; lazy-load развёрнутых выдержек протоколов.
- Читаемые ссылки на PDF протоколов ( `beautify_protocol_title` ).

Дополнительно: `docs/mvp-presentation.html`, `consult_review.html`.

## 8. Сводная схема текущей архитектуры



### 8.1. Поток «Поиск протоколов»

Запрос → МКБ ( `icd_mkb.py` + LLM) → retrieve → LLM формирует список протоколов с confidence → опционально protocol-detail.

### 8.2. Поток «Проверка КЗ»

Файл → pipeline → детерминированный compliance + RAG + LLM → отчёт с цитатами из официальных PDF.

## 9. Будущая интеграция с МИС и Минздравом

**Этап 2** Согласно [FHIR BY](#) и [регламенту МИС ОЗ – ЦИСЗ](#) (v1.4, FHIR 5.0.0):

### 9.1. Разделение ответственности

| Система  | Что проверяет                                                                         |
|----------|---------------------------------------------------------------------------------------|
| ЦИСЗ     | Профили FHIR, структура Bundle, справочники НСИ, OAuth 2.0, импорт пакета             |
| Protocol | Соответствие <i>содержания</i> КЗ клиническим протоколам Минздрава (ориентир, не МЭЭ) |
| МИС      | Формирование Bundle, ЭЦП, UI врача, вызов Protocol до подписи                         |
| Минздрав | Владелец корпуса КП, методические требования, пилоты, агрегированная аналитика        |

### 9.2. Точка встраивания в МИС

Врач заполняет КЗ в МИС

- МИС собирает FHIR Bundle (Patient, Encounter, Condition, Composition...)
- [НОВОЕ] вызов Protocol API (до ЭЦП)
- предупреждения / отчёт врачу
- врач исправляет (при необходимости)
- ЭЦП (ЕСИФЮЛ) → импорт в ЦИСЗ (202 Accepted → poll status)

### 9.3. Маппинг FHIR → Protocol

| FHIR BY                 | Protocol                             |
|-------------------------|--------------------------------------|
| Patient                 | PatientContext (пол, возраст)        |
| Condition + МКБ-10      | диагнозы, match_protocol_cards       |
| Observation             | витальные показатели в контексте КЗ  |
| Encounter               | care_setting, применимость протокола |
| Composition             | секции КЗ → consult_parser           |
| DocumentReference / PDF | текущий POST /api/consult-review     |

### 9.4. Планируемые фазы

| Фаза | Срок (ориентир) | Содержание                                                                                                                                         |
|------|-----------------|----------------------------------------------------------------------------------------------------------------------------------------------------|
| A    | 3–6 мес.        | REST из МИС: МКБ + текст → <code>/api/consult-review</code> ; кнопка «Проверить по протоколу»                                                      |
| B    | 6–12 мес.       | Адаптер <code>fhir_bundle_to_consult</code> ; endpoint <code>POST /api/fhir/consult-compliance</code> ; ответ в духе <code>OperationOutcome</code> |

| Фаза | Срок (ориентир) | Содержание                                                                              |
|------|-----------------|-----------------------------------------------------------------------------------------|
| С    | 12+ мес.        | On-premise в контуре РБ; дашборд Минздрава (агрегаты без ПДн); синхронизация корпуса КП |

## 9.5. Развёртывание

См. `docs/deployment-belarus.md` : сервер в контуре оператора/Минздрава, корпус на диске/S3, LLM – разрешённый API или on-premise модель в РБ, ПДн не выносить в публичный интернет.

## 10. Масштабирование: тысячи КЗ в сутки

При полной проверке каждого КЗ с LLM + RAG нагрузка растёт линейно. Ниже – меры ускорения и снижения стоимости.

### 10.1. Технические оптимизации

| Мера                                  | Эффект                                                                                                    |
|---------------------------------------|-----------------------------------------------------------------------------------------------------------|
| <b>Детерминированный fast path</b>    | Сначала rule_checker + requirement_checker без LLM; LLM только при пограничных баллах или по запросу      |
| <b>Кэш consult-review</b>             | <code>CONSULT_REVIEW_CACHE</code> – повторные проверки того же текста/хеша                                |
| <b>Очередь + воркеры</b>              | Celery/RQ: асинхронная обработка пакетов; API возвращает job_id, МИС опрашивает статус (аналог poll ЦИС3) |
| <b>Отключение embed-rerank</b>        | На batch-режиме: только lex + BM25 (уже есть флаг в CI)                                                   |
| <b>Предварительный digest</b>         | Сокращение текста КЗ до ключевых секций перед LLM (уже частично в pipeline)                               |
| <b>Горизонтальное масштабирование</b> | Несколько инстансов API за балансировщиком; корпус read-only на shared disk                               |
| <b>Инкрементальный corpus</b>         | Не перезагружать весь RAG при деплое – hot-reload index.csv                                               |

### 10.2. Ориентиры производительности (пилот)

- Детерминированный разбор одного КЗ (без LLM): секунды.
- Полная проверка с LLM: десятки секунд – минуты (зависит от длины и fast mode).
- Целевой batch: 100% КЗ – только детерминированный скоринг; 5–15% – углублённо с LLM.

## 11. Методика выборочного контроля качества КЗ

Цель: выявить врачей/подразделения с систематически слабыми КЗ без проверки каждого документа LLM.

### 11.1. Уровни выборки

| Уровень           | Охват     | Метод                                                                                                         |
|-------------------|-----------|---------------------------------------------------------------------------------------------------------------|
| L0 – скрининг     | 100% КЗ   | Только детерминированный скоринг (без LLM): оформление, МКБ, обязательные поля, red flags. < 1 с на документ. |
| L1 – выборка      | 10–20% КЗ | Случайная + стратифицированная по врачу, рубрике, итоговому L0-баллу.                                         |
| L2 – углублённо   | 2–5% КЗ   | Полный pipeline с RAG + LLM; эталон для методслужбы.                                                          |
| L3 – ручной аудит | 0.5–1%    | Эксперт методслужбы по списку «красных» врачей из L0–L2.                                                      |

### 11.2. Критерии отбора «проблемных» врачей

- Средний балл L0 за месяц < 70% при  $n \geq 10$  КЗ.
- Доля КЗ с критическими issues (red flags) > 15%.
- Тренд: снижение балла 3 месяца подряд.
- Выбросы: единичные КЗ < 50% при обычно нормальном профиле – в L2, не автоматическая санкция.

### 11.3. Агрегаты для Минздрава (без ПДн)

Учреждение, рубрика, период, средний % по блокам, доля «зелёных/жёлтых/красных» зон. Без ФИО пациентов; идентификатор врача – только внутри контура учреждения.

### 11.4. Хранение результатов

Таблица `kz_quality_scores`: hash текста, author\_id (из токена МИС), timestamp, LO\_score, flags, optional L2\_job\_id. Retention по политике ИБ.

## 12. Вариант: блокировка ЭЦП до нормы соответствия

**Опция для МИС** Не юридическое требование Protocol, а **настраиваемая политика учреждения**, согласуемая с Минздравом и юристами.

### 12.1. Режимы (config в МИС)

| Режим         | Поведение                                                                                  |
|---------------|--------------------------------------------------------------------------------------------|
| inform        | Только предупреждения; ЭЦП всегда доступна (текущий пилот).                                |
| soft_gate     | При балле < порога (напр. 70%) – диалог «Подписать всё равно?» + запись override в журнал. |
| hard_gate     | Кнопка ЭЦП неактивна, пока LO ≥ порога или методист не снял блок (workflow).               |
| critical_only | Блок только при critical red flags (безопасность, противопоказания).                       |

### 12.2. Техническая реализация в МИС

- МИС вызывает `POST /api/consult-review?mode=fast` или лёгкий `POST /api/consult-compliance-screen` (только LO).
- Ответ: `overall_compliance_pct`, `blocks`, `critical_issues[]`, `gate_allowed: bool`.
- МИС применяет локальную политику → разрешает/блокирует вызов ЕСИФЮЛ.
- При override – запись в audit log (врач, время, причина).

### 12.3. Риски и смягчение

- **Ложные срабатывания** – порог только по LO; спорные случаи – soft\_gate.
- **Юридическая нагрузка** – формулировка «ориентир методслужбы», не МЭЭ.
- **Соппротивление врачей** – пилот в одном отделении, обучение, прозрачные критерии из протоколов с цитатами.

## 13. Тестирование и качество

- **CI**: Ruff + pytest (~55 модулей), миникорпус `tests/fixtures/chunks.mini.jsonl`.
- **Eval**: `eval/golden_queries.jsonl` → `data/quality_benchmark.json` для UI.
- **Regression KZ**: `tests/test_regression_kz_compliance.py`, fixtures в `tests/fixtures/consultations/`.

## 14. Заключение

---

Protocol сегодня – монолитный MVP с двумя контурами: **LLM** для поиска и синтеза и **детерминированный clinical\_knowledge** для воспроизводимой проверки КЗ. Корпус привязан к официальному PDF Минздрава РБ.

Интеграция с МИС через FHIR BY логична *до подписи ЭЦП*: ЦИСЗ проверяет упаковку данных, Protocol – клиническое соответствие протоколам. Масштаб на тысячи КЗ достижим за счёт LO-скрининга, выборочного L2 и очередей; блокировка ЭЦП – опциональная политика учреждения, не обязательная часть MVP.

---

Protocol · Kravira · Документ сгенерирован для внутреннего использования и презентаций Минздраву/МИС. Ссылки: [fhir.by](https://fhir.by), [minzdrav.gov.by](https://minzdrav.gov.by), репозиторий protocol ([docs/roadmap-mis.md](#), [deployment-belarus.md](#)).