



Protocol: архитектура по этапам

Навигатор клинических протоколов Минздрава РБ и ориентировочная проверка консультативных заключений (КЗ).

Документ описывает текущую реализацию (MVP), целевую интеграцию с МИС и Минздравом через стандарт FHIR BY / ЦИСЗ, а также предложения по масштабированию на тысячи КЗ в сутки.

Версия документа: 2026-06-24 · Сборка приложения: `GET /api/version` · UI: mini-logo + pastel pill tabs; footer 4 карточки (врач) / расширенный набор в `?mode=methodist`.

1. Назначение и границы системы

MVP Protocol – веб-сервис и API для двух сценариев:

1. **Поиск протоколов** – подбор официальных КП Минздрава РБ по диагнозу, МКБ-10, жалобам и рубрикам каталога.
2. **Проверка КЗ** – ориентировочная сверка консультативного заключения с фрагментами протоколов и формализованными правилами; отчёт для врача и методслужбы.

Не входит: установление диагноза, замена очного приёма, МЭЭ, юридически обязательная экспертиза, прямая запись в медицинскую карту (на этапе пилота).

Два контура intelligence: (1) **LLM** – языковая модель для синтеза, уточнения запроса и дополнения ответа; (2) **детерминированный слой** `clinical_knowledge/` – парсинг, правила из протоколов, scoring без «магии» модели.

2. Этап 0. Корпус протоколов и справочники

2.1. Источник данных

Официальный каталог PDF на minzdrav.gov.by (раздел «Стандарты обследования и лечения»). Синхронизация скриптом `download_minzdrav_protocols.py` в каталог `minzdrav_protocols/` (~478 PDF, 24 рубрики).

2.2. Индекс каталога

`index.csv` - метаданные: рубрика, год в имени файла, признак постановления МЗ. Используется для UI-бейджей, статистики презентации и фильтрации.

2.3. Справочники

- `protocols.json`, `protocol_meta.json` - реестр путей и метаданные.
- `data/catalog/` - 85 нозологий, 482 автоизвлечённых правила, отчёт покрытия 100% PDF.
- `data/protocol_summaries/` - YAML/JSON карточки протоколов (~465 summaries) для навигации и расширения правил.
- `config/` - требования к КЗ, веса scoring, red flags.

3. Этап 1. Подготовка корпуса для RAG

3.1. Два пути сборки (legacy и новый)

Путь	Скрипты	Результат
Legacy	<code>extract_corpus.py</code> → <code>build_chunks.py</code> → <code>split_chunks_jsonl.py</code>	<code>corpus_chunks_parts/*.jsonl</code>
Новый	<code>corpus_pipeline/run_pipeline</code>	Секции, таблицы, entities → <code>output/chunks/</code>

3.2. Чанки RAG

~55 000 фрагментов текста с разметкой разделов (диагноз, лечение, обследование). Хранятся в `corpus_chunks_parts/` (JSONL) или на Persistent Disk (`RAG_CHUNKS_DIR`). На production (Render): **lazy chunk store** - manifest `corpus_path_manifest.jsonl`, чанки подгружаются с диска по пути PDF, без полной загрузки в RAM при старте (`RAG_STARTUP_MODE=manifest`, `RAG_LAZY_CHUNK_STORE=1`).

3.3. Индексы поиска

При загрузке или по требованию: path-scoped lex shards (`RAG_PATH_LEX_SHARDS`), BM25 (`retrieval_bm25.py`), опционально vector prefilter (`vector_index.py`), маршрутизация по симптомам (`symptom_routing.json`). Полный лексический индекс может откладываться (`RAG_LEX_INDEX_DEFER=1`) - L2-lite и поиск работают на суженном подмножестве путей.

4. Этап 2. Слой clinical_knowledge (детерминированный)

Каталог `clinical_knowledge/` (~118 модулей). Публичный API: `clinical_knowledge_status`, `match_protocol_cards`, `run_rule_checker`, `extract_consult_facts_heuristic`.

Блок	Модули	Функция
Схемы	<code>consult_schema.py</code>	ConsultationDocument, ComplianceReport, 8 блоков scoring
Парсинг КЗ	<code>consult_parser.py</code> , <code>text_extract.py</code> , <code>fhir_bundle_adapter.py</code>	PDF/TXT/DOCX/FHIR Bundle → структура документа
Подбор КП	<code>protocol_match.py</code> , <code>diagnosis_icd.py</code> , <code>respiratory_path_filters.py</code>	Сопоставление с протоколами по МКБ, рубрике; фильтры ложных матчей (ОРВИ)
Правила	<code>rule_checker.py</code> , <code>rules_from_path.py</code> , <code>semantic_rule_fallback.py</code>	482+ правил из PDF, покрытие по рубрикам, синонимы
Compliance	<code>compliance_engine.py</code> , <code>compliance_gate.py</code> , <code>safety_checker.py</code>	Итоговый отчёт, issues, send_gate, source_refs
Согласование КЗ	<code>consult_alignment.py</code> , <code>consult_criteria_enrichment.py</code> , <code>kravira_sop_rules.py</code>	Детерминированные карточки «КЗ ↔ КП ↔ СОП Кравира»; primary criteria в L1/L2-lite
L2-lite	<code>consult_l2_review.py</code> , <code>consult_evidence_pack.py</code> , <code>consult_memory.py</code>	Evidence pack по matched paths, L2-fast без полного RAG
ЦИСЗ	<code>cisz_readiness.py</code> , <code>fhir_mis_test_matrix.py</code>	Чек-лист готовности Bundle до импорта
Summaries	<code>protocol_summary/</code> , <code>plan_definition_export.py</code>	Карточки протоколов → rules → RAG; черновик FHIR PlanDefinition
Поиск	<code>search_tiering.py</code> , <code>search_retrieval.py</code> , <code>search_funnel.py</code>	Уровни S0/S1/S2, воронка подбора КП
Методслужба	<code>feedback_store.py</code> , <code>methodist_ai_review.py</code>	JSONL-разметка, workbench, экспорт для ML
Отчёты	<code>consult_report.py</code> , <code>batch_runner.py</code>	HTML/MD для печати, пакетная обработка

Оркестратор: `consult_analysis.analyze_consultation_text()`. Уровни L0/L1/L2: `consult_tiering.py`.
Production pipeline: `consult_review_pipeline.py`.

5. Этап 3. Runtime: rag_server.py (FastAPI)

5.1. Стек

Python 3.11+, FastAPI, uvicorn. Учётные данные для вызова языковой модели задаются только в конфигурации сервера (переменные окружения или защищённое хранилище секретов) и не передаются в браузер.

5.2. Загрузка при старте

Фоновый поток `load_data()` : manifest/lazy chunks, protocols, meta, summary chunks, path lex shards.
`GET /health/live` - liveness без ожидания полного RAG; `GET /health` - готовность индексов и флаги consult L2. На Render: Persistent Disk 10 GB (`/var/data`), plan Standard 2 GiB RAM.

5.3. Гибридный retrieve

Функция `retrieve()` : лексика + BM25 + routing boost + фильтр аудитории + опциональный embed-rerank через LLM. Результат - топ фрагментов по протоколам.

5.4. Группы API

Домен	Endpoints
Health	<code>GET /health</code> , <code>/api/version</code> , <code>/api/corpus-stats</code>
Поиск	<code>POST /api/assist</code> , <code>/api/search/run</code> , <code>/api/search/funnel</code> , <code>/api/protocol-detail</code> , <code>/api/protocol-practical</code> , tiers S0/S1/S2
КЗ	<code>POST /api/consult-review</code> , <code>/api/consult-review/stream</code> (SSE), <code>/api/consult-review/tier</code> , <code>/api/consult-compliance-screen</code>
Справочники	<code>/api/specialties</code> , <code>/api/icd-suggest</code> , <code>/api/training-cases</code> , <code>/api/protocol-summary-nav</code>
Методслужба	<code>/api/methodist/*</code> , <code>/api/ml/feedback</code> , <code>/api/pilot-analytics-demo</code>
Clinical knowledge	<code>/api/clinical-knowledge/status</code> , <code>/build-status</code> , <code>/benchmark</code>

6. Этап 4. Проверка КЗ (pipeline)

Модуль `consult_review_pipeline.py` - оркестрация с SSE-прогрессом для UI. Маршрутизация уровней: `consult_tiering.py`.

6.1. Уровни L0 / L1 / L2

Уровень	API	Содержание	Production (Render)
L0	<code>/api/consult-compliance-screen</code> , tier=L0	Парсинг + 8 блоков + <code>send_gate</code> + <code>cisz_readiness</code>	< 2 с, без RAG/LLM
L1	<code>/api/consult-review/tier</code> L1	Structured + alignment cards + СОП Кравира + rich chunks по matched PDF	Рекомендуемый в UI (~5-15 с)
L2	<code>/api/consult-review</code> , stream	L2-lite: L1 + evidence pack + L2-fast; опц. L2+ narrative	~15-30 с, без retrieve по всему корпусу
L2 full	local, <code>CONSULT_RENDER_L2_LITE=0</code>	RAG retrieve + LLM synthesize + hybrid score	30-90 с (не default на Render)

6.2. Конвейер L1 (основной для врача)

PDF / FHIR Bundle / текст

- извлечение и парсинг → ConsultationDocument
- МКБ-10 + match_protocol_cards (allowlist)
- analyze_consultation_text → 8 блоков + evidence_map
- consult_alignment: карточки «КЗ ↔ КП ↔ СОП №2 Кравира»
- consult_criteria_enrichment: выдержки и покрытие по блокам
- compliance_gate: gate_score = min(гибрид, структурный, cisz)
- cisz_readiness + send_gate + HTML/MD отчёт

6.3. Конвейер L2-lite (облако)

L1 structured + alignment (skip_alignment=false)

- preload чанков только по matched paths (consult_memory)
- consult_evidence_pack: выдержки КП с фильтром качества
- build_l2_fast_review (CONSULT_L2_FAST=1) ИЛИ LLM synthesize
- опц. consult_criteria_narrative (CONSULT_CRITERIA_NARRATIVE)
- кэш CONSULT_REVIEW_CACHE, cisz_readiness

Флаги Render: `CONSULT_RENDER_L2_LITE=1`, `CONSULT_REVIEW_FORBID_FULL_CORPUS=1`, `CONSULT_ALIGNMENT_ENABLED=1`. При нехватке RAM (`CONSULT_RENDER_L2_SKIP_LLM=1`) L2 деградирует в L1 с пометкой в ответе.

7. Этап 5. Frontend

Два клиентских shell в production: B2B `index.html` (~29k строк) и B2C `patient.html` (~1,1k строк + `patient-ui.js`). Inline CSS + vanilla JS, без bundler.

7.1. index.html (B2B)


- **Липкая шапка:** mini-logo `protocol-logo-mini.svg` и вкладки «Проверка КЗ» / «Поиск протоколов» в одну строку; pill-стиль с пастельной заливкой.
- **Вкладки:** «Проверка КЗ» (`#consult-review`), «Поиск протоколов» (`#search`); «Статистика поиска» - в footer; hash сохраняется при F5.
- **Footer (врач):** четыре карточки - статистика, B2C, презентация MVP, вход в кабинет методиста; буклет, архитектура PDF и чек-лист - только в `?mode=methodist`.
- **Методслужба:** `?mode=methodist` + токен - workbench, очередь (`#methodist-queue`), ML-дашборд (`#ml-dashboard`), B2C-тарифы (`#b2c-monetization`).
- **Structured analysis:** 8 блоков compliance, alignment, evidence pack; SSE для потоковой проверки КЗ.

7.2. patient.html (B2C «Проверь КЗ»)

- Отдельная PWA: загрузка PDF/фото КЗ, отчёт простым языком, tier-цены, white-label клиники.
- API: `POST /api/patient/review`, sanitize без полей B2B; см. `docs/architecture-b2c-patient.md`.

Подробная архитектура проверки КЗ перед отправкой в Минздрав: [architecture-kravira-fhir-mis.pdf](#) (HTML-исходник для печати: `architecture-kravira-fhir-mis-print.html`). Также: `docs/mvp-presentation.html`, `docs/pre-sign-checklist-print.html`, `docs/project-docs-maintenance.md`.

8. Сводная схема текущей архитектуры



8.1. Поток «Поиск протоколов»

Запрос → МКБ (`icd_mkb.py` + LLM на S2) → retrieve (lazy, allowlist на Render) → список протоколов с confidence → protocol-detail / practical / summary-nav. Уровни S0 (только МКБ), S1 (retrieve без полного assist, default), S2 (полный ответ модели).

8.2. Поток «Проверка КЗ»

Файл или Bundle → L0/L1/L2 → детерминированный compliance + alignment + (на L2-lite) evidence pack → gate_score и send_gate → отчёт с цитатами из официальных PDF. Итог для МИС: `gate_score = min(клиника, cisz_score)`.

9. Будущая интеграция с МИС и Минздравом

Этап 2 Согласно [FHIR BY](#) и [регламенту МИС ОЗ - ЦИСЗ](#) (v1.4, FHIR 5.0.0):

9.1. Разделение ответственности

Система	Что проверяет
ЦИСЗ	Профили FHIR, структура Bundle, справочники НСИ, OAuth 2.0, импорт пакета
Protocol	Соответствие <i>содержания</i> КЗ клиническим протоколам Минздрава (ориентир, не МЭЭ)
МИС	Формирование Bundle, ЭЦП, UI врача, вызов Protocol до подписи
Минздрав	Владелец корпуса КП, методические требования, пилоты, агрегированная аналитика

9.2. Точка встраивания в МИС

Врач заполняет КЗ в МИС

- МИС собирает FHIR Bundle (Patient, Encounter, Condition, Composition...)
- [НОВОЕ] вызов Protocol API (до ЭЦП)
- предупреждения / отчёт врачу
- врач исправляет (при необходимости)
- ЭЦП (ЕСИФЮЛ) → импорт в ЦИСЗ (202 Accepted → poll status)

9.3. Маппинг FHIR → Protocol

FHIR BY	Protocol
Patient	PatientContext (пол, возраст)
Condition + МКБ-10	диагнозы, match_protocol_cards
Observation	витальные показатели в контексте КЗ
Encounter	care_setting, применимость протокола
Composition	секции КЗ → consult_parser
DocumentReference / PDF	текущий POST /api/consult-review

9.4. Планируемые фазы

Фаза	Срок (ориентир)	Содержание
A	3-6 мес.	REST из МИС: МКБ + текст → <code>/api/consult-review</code> ; кнопка «Проверить по протоколу»
B	6-12 мес.	Адаптер <code>fhir_bundle_to_consult</code> ; endpoint <code>POST /api/fhir/consult-compliance</code> ; ответ в духе OperationOutcome

Фаза	Срок (ориентир)	Содержание
С	12+ мес.	On-premise в контуре РБ; дашборд Минздрава (агрегаты без ПДн); синхронизация корпуса КП

9.5. Развёртывание

См. `docs/deployment-belarus.md` : сервер в контуре оператора/Минздрава, корпус на диске/S3, LLM - разрешённый API или on-premise модель в РБ, ПДн не выносить в публичный интернет.

10. Масштабирование: тысячи КЗ в сутки

При полной проверке каждого КЗ с LLM + RAG нагрузка растёт линейно. Ниже - меры ускорения и снижения стоимости.

10.1. Технические оптимизации

Мера	Эффект
Детерминированный fast path	Сначала rule_checker + requirement_checker без LLM; LLM только при пограничных баллах или по запросу
Кэш consult-review	<code>CONSULT_REVIEW_CACHE</code> - повторные проверки того же текста/хеша
Очередь + воркеры	Celery/RQ: асинхронная обработка пакетов; API возвращает job_id, МИС опрашивает статус (аналог poll ЦИС3)
Отключение embed-rerank	На batch-режиме: только lex + BM25 (уже есть флаг в CI)
Предварительный digest	Сокращение текста КЗ до ключевых секций перед LLM (уже частично в pipeline)
Горизонтальное масштабирование	Несколько инстансов API за балансировщиком; корпус read-only на shared disk
Инкрементальный corpus	Не перезагружать весь RAG при деплое - hot-reload index.csv

10.2. Ориентиры производительности (пилот)

- Детерминированный разбор одного КЗ (без LLM): секунды.
- Полная проверка с LLM: десятки секунд - минуты (зависит от длины и fast mode).
- Целевой batch: 100% КЗ - только детерминированный скоринг; 5-15% - углублённо с LLM.

11. Семантический RAG и пять фаз ускорения (реализовано)

Аддитивный контур поверх существующего lex+BM25+rules. Детерминированный scoring не заменяется.

Фаза	Модули / скрипты	Эффект
1	<code>scripts/build_chunk_embeddings.py</code> , <code>scripts/corpus_manifest.py</code> , <code>RAG_PRECOMPUTED_CHUNK_EMBED</code>	Офлайн-эмбединги чанков; один API-вызов на запрос вместо пула ~44
2	<code>clinical_knowledge/vector_index.py</code> , <code>scripts/build_vector_index.py</code> , <code>RAG_VECTOR_INDEX</code>	Vector top-200 → lex/BM25 → embed-rerank top-44; FAISS или numpy
3	<code>semantic_rule_fallback.py</code> , <code>RULE_SEMANTIC_FALLBACK</code>	Синонимы/токены для <code>required_exam</code> и <code>keyword_presence</code> после substring
4	<code>consult_tiering.py</code> , <code>POST /api/consult- review/tier</code>	L0/L1/L2 для массового потока МИС без полного LLM на 100% КЗ
4b	<code>consult_alignment.py</code> , <code>kravira_sop_rules.py</code> , <code>consult_criteria_enrichment.py</code>	Детерминированные карточки согласования; primary criteria в production
5	<code>scripts/enrich_protocol_rules_batch.py</code> , <code>data/catalog/enrichment/</code>	Batch LLM → structured rules (<code>required_exam</code> , red flags) в <code>rule_checker</code>

11.1. Порядок развёртывания корпуса

1. Собрать смысловые чанки: `corpus_pipeline/run_pipeline.py` → `split_chunks_jsonl.py`
2. Офлайн embeddings: `python3 scripts/build_chunk_embeddings.py`
3. Индекс: `python3 scripts/build_vector_index.py` (опционально `pip install -r requirements-
vector.txt`)
4. Манифест: `python3 scripts/corpus_manifest.py`
5. Prod env: `RAG_PRECOMPUTED_CHUNK_EMBED=1` , `RAG_VECTOR_INDEX=1`

11.2. Eval

`eval/search_quality_eval.py --embed-on --precomputed-on --vector-on` - сравнение с golden queries.

12. Методика выборочного контроля качества КЗ

Цель: выявить врачей/подразделения с систематически слабыми КЗ без проверки каждого документа LLM.

12.1. Уровни выборки

Уровень	Охват	Метод
L0 - скрининг	100% КЗ	<code>POST /api/consult-review/tier tier=L0</code> или <code>/api/consult-compliance-screen</code> . < 1 с, без LLM/RAG.
L1 - выборка	10-20% КЗ	<code>tier=L1</code> : structured + alignment + СОП + rich chunks; без полного corpus RAG.
L2 - углублённо	2-5% КЗ	<code>tier=L2</code> : на Render - L2-lite (evidence pack + L2-fast); локально - full RAG + LLM.
L3 - ручной аудит	0.5-1%	Эксперт методслужбы по списку «красных» врачей из L0-L2.

12.2. Критерии отбора «проблемных» врачей

- Средний балл L0 за месяц < 70% при $n \geq 10$ КЗ.
- Доля КЗ с критическими issues (red flags) > 15%.
- Тренд: снижение балла 3 месяца подряд.
- Выбросы: единичные КЗ < 50% при обычно нормальном профиле - в L2, не автоматическая санкция.

12.3. Агрегаты для Минздрава (без ПДн)

Учреждение, рубрика, период, средний % по блокам, доля «зелёных/жёлтых/красных» зон. Без ФИО пациентов; идентификатор врача - только внутри контура учреждения.

12.4. Хранение результатов

Таблица `kz_quality_scores` : hash текста, `author_id` (из токена МИС), `timestamp`, `L0_score`, `flags`, optional `L2_job_id`. Retention по политике ИБ.

13. Вариант: блокировка ЭЦП до нормы соответствия

Опция для МИС Не юридическое требование Protocol, а **настраиваемая политика учреждения**, согласуемая с Минздравом и юристами.

13.1. Режимы (config в МИС)

Режим	Поведение
inform	Только предупреждения; ЭЦП всегда доступна (текущий пилот).
soft_gate	При балле < порога (напр. 70%) - диалог «Подписать всё равно?» + запись override в журнал.
hard_gate	Кнопка ЭЦП неактивна, пока L0 ≥ порога или методист не снял блок (workflow).
critical_only	Блок только при critical red flags (безопасность, противопоказания).

13.2. Техническая реализация в МИС

- МИС вызывает `POST /api/consult-review?mode=fast` или лёгкий `POST /api/consult-compliance-screen` (только L0).
- Ответ: `overall_compliance_pct`, `blocks`, `critical_issues[]`, `gate_allowed: bool`.
- МИС применяет локальную политику → разрешает/блокирует вызов ЕСИФЮЛ.
- При override - запись в audit log (врач, время, причина).

13.3. Риски и смягчение

- Ложные срабатывания** - порог только по L0; спорные случаи - soft_gate.
- Юридическая нагрузка** - формулировка «ориентир методслужбы», не МЭЭ.
- Соппротивление врачей** - пилот в одном отделении, обучение, прозрачные критерии из протоколов с цитатами.

14. Тестирование и качество

- CI:** Ruff + pytest (~70+ модулей), миникорпус `tests/fixtures/chunks.mini.jsonl`.
- Eval:** `eval/search_quality_eval.py`, `eval/golden_queries.jsonl` → `data/quality_benchmark.json`.
- Regression KZ:** `tests/test_consult_alignment.py`, `test_consult_criteria_enrichment.py`, `test_consult_evidence_quality.py`, fixtures в `tests/fixtures/consultations/`.

15. Заключение

Protocol сегодня - монолитный MVP с тремя контурами оценки КЗ: **детерминированный compliance** (8 блоков + send_gate), **alignment cards** (КЗ ↔ КП ↔ СОП Кравира) и опциональный **LLM** для поиска и углублённого L2. Корпус привязан к официальным PDF Минздрава РБ; на production - lazy chunk store и L2-lite без полного RAG по ~55k чанкам.

Интеграция с МИС через FHIR BY логична *до подписи ЭЦП*: ЦИСЗ проверяет упаковку данных, Protocol - клиническое соответствие протоколам. Масштаб на тысячи КЗ достижим за счёт L0-скрининга, выборочного L2 и очередей; блокировка ЭЦП - опциональная политика учреждения, не обязательная часть MVP.

Protocol · Kravira · Документ сгенерирован для внутреннего использования и презентаций Минздраву/МИС. Ссылки: fhir.by, minzdrav.gov.by, репозиторий protocol (docs/roadmap-mis.md, deployment-belarus.md).